

Восстановление парных зависимостей из групп непарных данных

Д. И. Казачков

МФТИ

Научный руководитель: А. А. Коротин

2026

Постановка задачи

Есть M независимых групп. В группе n исходно были пары


$$(x_1^n, y_1^n), \dots, (x_M^n, y_M^n),$$

но элементы Y перемешаны неизвестной перестановкой σ^n :

$$\{x_m^n\}_{m=1}^M, \quad \{y_{\sigma^n(m)}^n\}_{m=1}^M.$$

Правдоподобие одной группы при латентной перестановке:

$$p(y^n | x^n) = \sum_{\sigma^n \in S_M} p(\sigma^n) \prod_{m=1}^M p(y_{\sigma^n(m)}^n | x_m^n).$$



неизвестная перестановка

Комбинаторная сложность

Сумма содержит $M!$ слагаемых. Уже при $M = 20$ прямой подсчёт невозможен.

Мотивация

Существующее решение (Beier et al.) — заменить общую перестановку на совокупность независимых сопоставлений

$$\sigma^n(m) \in \{1, \dots, M\}.$$

$$\sum_{\sigma^n} p(\sigma^n) \prod_{m=1}^M p(y_{\sigma^n(m)}^n | x_m^n) \rightsquigarrow \prod_{m=1}^M \sum_{\sigma^n(m)} p(\sigma^n(m)) p(y_{\sigma^n(m)}^n | x_m^n).$$

Плюс

Нет суммы по $M!$ перестановкам.

Минус

Биективность теряется: несколько x_m могут выбрать один и тот же y_k .

Идея работы: $\log p(y^n | x^n)$ оценить снизу вариационной нижней оценкой и максимизировать уже её:

$$\log p(y^n | x^n) \geq \text{ELBO}(\theta, \phi) \xrightarrow{\theta, \phi} \max,$$

где перестановка σ — латентная переменная.

Posterior скрытой перестановки

Истинный posterior скрытой перестановки:

$$p_{\theta}(\sigma \mid x, y) = \frac{p_{\theta}(y, \sigma \mid x)}{p_{\theta}(y \mid x)} = \dots = \frac{p(\sigma) \prod_{m=1}^M p_{\theta}(y_{\sigma(m)} \mid x_m)}{\sum_{\sigma' \in S_M} p(\sigma') \prod_{m=1}^M p_{\theta}(y_{\sigma'(m)} \mid x_m)}.$$

Знаменатель всё ещё содержит $M!$ слагаемых. Вводим вариационное распределение на всём S_M :

$$q(\sigma \mid x, y) \geq 0, \quad \sum_{\sigma \in S_M} q(\sigma \mid x, y) = 1.$$

$$p_{\theta}(y \mid x) = \sum_{\sigma \in S_M} q(\sigma) \frac{p_{\theta}(y, \sigma \mid x)}{q(\sigma)} \Rightarrow \log p_{\theta}(y \mid x) \geq \mathbb{E}_q \left[\log \frac{p_{\theta}(y, \sigma \mid x)}{q(\sigma)} \right] := \mathcal{E}(q, \theta; x, y),$$

$$\mathcal{E}(q, \theta; x, y) = \mathbb{E}_q [\log p_{\theta}(y, \sigma \mid x) - \log q(\sigma)]$$

$$= \mathbb{E}_{q(\sigma \mid x, y)} \left[\sum_{m=1}^M \log p_{\theta}(y_{\sigma(m)} \mid x_m) \right] - \text{KL}(q(\sigma \mid x, y) \parallel \text{Unif}(S_M)).$$

$$\mathcal{L}_{\text{NELBO}}(\theta, q) = \frac{1}{N} \sum_{n=1}^N \left[\mathbb{E}_{q_n} \left[- \sum_{m=1}^M \log p_{\theta}(y_{\sigma(m)}^n \mid x_m^n) \right] + \text{KL}(q_n(\sigma) \parallel \text{Unif}(S_M)) \right].$$

Но это в предположении $p(\sigma) \sim \text{Unif}(S_M)$. А с истинным posterior как это соотносится?

$$\log p_{\theta}(y \mid x) = \mathcal{E}(q, \theta; x, y) + \text{KL}(q(\sigma \mid x, y) \parallel p_{\theta}(\sigma \mid x, y)).$$

Максимизируем $\mathcal{E}(q, \theta)$.

Как представить и оптимизировать $q(\sigma \mid x, y)$? Как параметризовать $p_{\theta}(y \mid x)$?

Нейросетевой вариационный подход

Два распределения параметризуются нейросетями и обучаются совместно:

- $q_\phi(\sigma \mid x, y)$ задаётся энкодером и Gumbel–Sinkhorn-релаксацией мягкой матрицы перестановки $Z \in \mathcal{B}_M$.
- $p_\theta(y \mid x)$ задаётся декодером как условная wrapped Gaussian mixture.
- Точный KL на S_M недоступен для Gumbel–Sinkhorn-распределения, поэтому в реализации используется дифференцируемый surrogate loss.

$$D_{mk}^n = -\log p_\theta(y_k^n \mid x_m^n),$$

$$\mathcal{L}^n = \sum_{m,k} z_{mk}^n D_{mk}^n + \beta \frac{1}{M} \sum_{m,k} z_{mk}^{n,\text{det}} (\log z_{mk}^{n,\text{det}} + \log M).$$

CatVAE: энкодер


Энкодер по *всем* парам (x_m^n, y_k^n) строит матрицу логитов:

$$\Phi_{mk} = f_{\phi}([\sin 2\pi x_m^n, \cos 2\pi x_m^n, \sin 2\pi y_k^n, \cos 2\pi y_k^n]).$$

Если нормировать только строки, получится локальное распределение кандидатов:

$$\Pr(k \mid m) = \frac{\exp(\Phi_{mk})}{\sum_{k'=1}^M \exp(\Phi_{mk'})}.$$

Но это только мотивационный промежуточный вариант: построчная нормировка *не* гарантирует биективность, так как несколько x_m могут выбрать один y_k .



CatVAE: преобразование в латентном пространстве

Энкодер выдаёт логиты $\Phi_{mk} = f_\phi([\sin 2\pi x_m, \cos 2\pi x_m, \sin 2\pi y_k, \cos 2\pi y_k]) \in \mathbb{R}^{M \times M}$.
В общем случае эта матрица *не* перестановочна; превращаем её в мягкую перестановку $Z \in \mathcal{B}_M$.

1. **Gumbel trick:** добавляем шум и делим на температуру τ

$$\tilde{\Phi}_{mk} = \frac{\Phi_{mk} + G_{mk}}{\tau}, \quad G_{mk} \sim \text{Gumbel}(0, 1).$$

2. **Sinkhorn-Knopp в log-space:** последовательно нормируем строки и столбцы

$$\tilde{\Phi}_{mk}^{(t+\frac{1}{2})} = \tilde{\Phi}_{mk}^{(t)} - \log \sum_{j=1}^M \exp \tilde{\Phi}_{mj}^{(t)}, \quad \tilde{\Phi}_{mk}^{(t+1)} = \tilde{\Phi}_{mk}^{(t+\frac{1}{2})} - \log \sum_{i=1}^M \exp \tilde{\Phi}_{ik}^{(t+\frac{1}{2})}.$$

Тогда матрица сопоставлений определяется так:


$$Z = \exp(\tilde{\Phi}^{(T)}) \in \mathcal{B}_M, \quad Z_{mk} \geq 0, \quad \sum_k Z_{mk} \approx 1, \quad \sum_m Z_{mk} \approx 1.$$

CatVAE: преобразование в латентном пространстве

Энкодер выдаёт логиты $\Phi_{mk} = f_{\phi}(\dots)$.

Gumbel–Sinkhorn переводит логиты в матрицу сопоставлений $Z \in \mathcal{B}_M$.

- Z_{mk} задает степень соответствия x_m и y_k .
- Дважды стохастическая Z задает релаксацию биективного сопоставления.
- Температура τ : большая — масса распределяется более равномерно по строкам и столбцам; малая — Z близка к разреженной дважды стохастической матрице.
- В основных экспериментах $\tau = 1$ фиксирована на протяжении запуска.
- Операция дифференцируема $\Rightarrow$ энкодер обучается end-to-end градиентами через Z .



Декодер: wrapped Gaussian mixture


Энкодер выдаёт логиты $\Phi_{mk} = f_{\phi}(\dots)$.

Gumbel–Sinkhorn выдаёт матрицу сопоставлений $Z \in \mathcal{B}_M$.

Декодер задаёт условную плотность как смесь K компонент:

$$p_{\theta}(y | x) = \sum_{c=1}^K \pi_c(x) \tilde{\mathcal{N}}(y | \mu_c(x), \epsilon^2).$$

- $\mu_c(x)$ и logits для $\pi_c(x)$ выдаёт MLP по признакам $[\sin(2\pi x), \cos(2\pi x)]$; его обучаемые веса — это параметры θ .
- $\tilde{\mathcal{N}}$ — гауссовская плотность, обёрнутая на тор через $z \mapsto z \bmod 1$.
- ϵ^2 фиксирована и совпадает с дисперсией шума генератора.
- Для синтетических экспериментов используется $K = 2$.




Синтетические данные на торе

Работаем на $S^1 = [0, 1)$:

$$P_{\text{data}}(x) := \mathcal{U}[0, 1), \quad X \in [0, 1),$$

$$P_{\text{data}}(y | x) := \frac{1}{2} \tilde{\mathcal{N}}(x, \epsilon^2) + \frac{1}{2} \tilde{\mathcal{N}}(x+0.3, \epsilon^2)$$

После генерации пар внутри каждой группы элементы Y перемешиваются случайной перестановкой.




Две диагональные полосы: $y \approx x$ и $y \approx x + 0.3$.

Метрика восстановления плотности

Так как $X \sim \mathcal{U}[0, 1)$, $p(x, y) = p(y | x)$. На сетке $E \times E$ считаем


$$L_2 = \frac{1}{E} \|p_{\text{true}}(x, y) - \hat{p}_{\theta}(x, y)\|_2, \quad E = 100.$$

Эксперимент 1: влияние размера группы M




- Рост M увеличивает пространство перестановок как $M!$.
- Для малых M плотность восстанавливается конкурентно.
- При больших M bottleneck переходит в качество matching/энкодера.

Эксперимент 2: влияние объёма данных N




- Увеличение числа групп помогает оценке плотности, но не решает полностью matching-задачу.
- Для больших M важна не только статистика, но и архитектура inference-модели.


Эксперимент 3: сравнение восстановления плотности



$\epsilon = 0.025, M = 2$



$\epsilon = 0.01, M = 2$



$\epsilon = 0.05, M = 2$

- Модель восстанавливает периодичность и диагональную структуру.
- При росте ϵ моды сильнее перекрываются, matching становится неоднозначнее.
- Для малых групп ассигнату существенно выше случайного baseline.

ЕМ: вероятностная модель

К условному распределению

$$p_{\theta}(y \mid x) = \sum_{c=1}^K \pi_c \tilde{\mathcal{N}}(y \mid x + s_c, \epsilon^2),$$

с параметрами $\theta = (\pi_1, \dots, \pi_K, s_1, \dots, s_K)$ добавляется набор скрытых переменных $c_m \in \{1, \dots, K\}$. Тогда вероятностная модель:

$$p_{\theta}(y, \sigma, c \mid x) = p(\sigma) \prod_{m=1}^M \pi_{c_m} \tilde{\mathcal{N}}(y_{\sigma(m)} \mid x_m + s_{c_m}, \epsilon^2).$$

ЕМ: E-шаг

При текущих параметрах $\theta^{(t)}$ для каждой пары вычисляется лог-правдоподобие пары

$$L_{mk} = \log p_{\theta^{(t)}}(y_k | x_m) = \log \sum_{c=1}^K \pi_c^{(t)} \tilde{\mathcal{N}}(y_k | x_m + s_c^{(t)}, \epsilon^2).$$

насколько вероятно, что x_m
соответствует y_k

$$Q = \text{Sinkhorn}\left(\frac{L}{\tau}\right).$$

если (x_m, y_k) , то какая
компонента c объясняет
эту пару?

$$W_{mkc} = \frac{\pi_c \tilde{\mathcal{N}}(y_k | x_m + s_c, \epsilon^2)}{\sum_{c'} \pi_{c'} \tilde{\mathcal{N}}(y_k | x_m + s_{c'}, \epsilon^2)}$$

Совместный приближённый вес считается как

$$R_{mkc} = Q_{mk} W_{mkc}.$$

Эту формулу можно понимать $R_{mkc} \approx \Pr[\sigma(m) = k, c_m = c | x, y, \theta]$.


Обновление весов смеси

$$\pi_c \leftarrow \frac{S_c}{\sum_{c'} S_{c'}}, \quad S_c = \sum_{n,m,k} R_{mkc}^{(n)}.$$

Обновление сдвигов компонент


$$s_c \leftarrow \frac{1}{2\pi} \operatorname{atan2} \left(\sum_{n,m,k} R_{mkc}^{(n)} \sin(2\pi \delta_{mk}^n), \sum_{n,m,k} R_{mkc}^{(n)} \cos(2\pi \delta_{mk}^n) \right) \bmod 1$$

ЕМ: эксперименты при $\tau = 1$







ЕМ: зависимость L_2 от M

- При $\tau = 1$ ошибка смеси сдвигов не растёт с увеличением M в исследованном диапазоне.
- С ростом N параметры сдвигов и весов оцениваются точнее, ошибка стремится к малым значениям.
- Преимущество связано с правильно специфицированной моделью генератора.




ЕМ: зависимость L_2 от N


EM: чувствительность к температуре




$\tau = 0.05$




$\tau = 0.1$



$\tau = 0.2$



$\tau = 0.5$



При малой τ Sinkhorn-план становится почти жёстким: ответственность может схлопнуться в одну компоненту, поэтому возникает плато ошибки.

Выносятся на защиту

- 1 Выведена вариационная нижняя граница для точной скрытой перестановки группы, без факторизации по локальным назначениям.
- 2 Разработан CatVAE с Gumbel–Sinkhorn-энкодером и декодером условной обёрнутой гауссовой смеси; модель амортизирует вывод для новых групп.
- 3 На синтетическом торе исследовано влияние M , N и уровня шума ϵ ; CatVAE даёт качество, сопоставимое с референсом по L_2 -ошибке плотности.
- 4 Разработан подход с глобальной смесью сдвигов и модифицированным ЕМ; преимущество на бенчмарке связано с правильно специфицированной моделью генератора.

Работа представлена на Всероссийской научной конференции МФТИ.