

Аннотация

Восстановление парных зависимостей из групп непарных данных
Казачков Даниил Иванович

Аннотация

Работа посвящена восстановлению зависимости между двумя наборами величин, которые наблюдаются группами, но исходное соответствие между их элементами утрачено. Цель работы состоит в разработке метода, позволяющего по таким данным одновременно оценивать скрытое сопоставление и общую статистическую зависимость. Сформулирована вероятностная модель задачи и предложены два подхода с разными параметризациями. Нейросетевой вариационный автоэнкодер обучается стохастическим градиентным методом, а модель глобальной смеси сдвигов — модифицированным ЕМ-алгоритмом с Sinkhorn-аппроксимацией Е-шага и аналитическими обновлениями параметров. Исследовано влияние уровня шума, размера групп и объёма данных. Эксперименты на синтетических периодических данных показали, что оба подхода способны восстанавливать скрытые пары и соответствующее распределение данных. Нейросетевой подход обрабатывает новые группы без повторной оптимизации и показывает качество, сопоставимое с существующим методом. Подход с явной смесью достигает более высокой точности, когда его предположения совпадают со структурой данных. Установлено, что качество снижается при увеличении размера групп и сильном перекрытии возможных соответствий.

Содержание

1	Введение	4
1.1	Мотивация задачи	4
1.2	Проблема существующих подходов	4
1.3	Цель и основные результаты	5
2	Обзор и постановка задачи	6
2.1	Обозначения	6
2.2	Формальная постановка задачи	6
2.3	Аппроксимация Байера и др.	7
2.4	Жёсткое назначение в нейросетевых моделях	7
3	Метод	9
3.1	Нейросетевой вариационный подход	9
3.1.1	Вариационная целевая функция	9
3.1.2	Gumbel–Sinkhorn-параметризация перестановки	10
3.1.3	Нейросетевой энкодер	11
3.1.4	Нейросетевой декодер	12
3.1.5	Обучение стохастическим градиентным методом	13
3.2	Подход с явными смесями	14
3.2.1	Явная параметризация распределений	14
3.2.2	Модифицированный E-шаг	15
3.2.3	Аналитический M-шаг	15
4	Эксперименты	17
4.1	Синтетические данные	17
4.2	Метрики и протокол	17
4.3	Восстановление скрытого сопоставления	19
4.4	Влияние размера группы M	20
4.5	Влияние числа групп N	20
5	Обсуждение	23
5.1	Сравнение предложенных подходов	23
5.2	Интерпретация экспериментальных результатов	23
5.3	Границы применимости	24
5.4	Открытые задачи	24
5.5	Основные результаты	25

1 Введение

1.1 Мотивация задачи

Во многих прикладных задачах данные поступают группами, внутри которых наблюдаются две совокупности совместно порождённых величин, но соответствие между их элементами утрачено. Это происходит, например, при раздельном измерении двух модальностей, обезличивании записей или независимом переупорядочивании результатов. В каждой группе известны только два набора значений, тогда как неизвестно, какие элементы образуют пары.

Регистрация облаков точек. В компьютерном зрении и медицинской визуализации требуется совмещать облака точек, описывающие один объект в разных системах координат. Отдельные точки двух облаков могут соответствовать одним и тем же частям объекта, однако это соответствие непосредственно не наблюдается. По нескольким таким группам требуется восстановить закономерность, связывающую координаты в двух системах.

Кросс-модальный анализ одноклеточных данных. Различные молекулярные характеристики клетки нередко измеряются на разных клетках из одной популяции. Отдельная выборка клеток образует группу, для которой доступны наборы измерений двух модальностей, но неизвестно, какие значения относятся к одной клетке. Восстановленная зависимость позволяет предсказывать одну молекулярную характеристику по другой.

Эти примеры различаются предметной областью, но приводят к общей статистической задаче: по повторяющимся группам непарных наблюдений восстановить как скрытые пары, так и общую зависимость между двумя величинами. При этом в обучающей выборке нет наблюдений с достоверно известным попарным соответствием, по которым эту зависимость можно было бы оценить непосредственно.

1.2 Проблема существующих подходов

Вероятностная постановка восстановления условного закона из групп непарных точек предложена Байером и др. [1]. Неизвестное внутригрупповое соответствие в ней трактуется как скрытая перестановка, а вычислительная аппроксимация строится с помощью энтропийных транспортных ядер. Этот подход служит основной точкой сравнения в настоящей работе.

Точное маргинальное правдоподобие модели со скрытой перестановкой содержит сумму по $M!$ допустимым сопоставлениям для группы размера M . Поэтому прямое вероятностное оценивание становится вычислительно недоступным уже при умеренных M . Кроме того, транспортное сопоставление для новой группы вычисляется заново и не использует обученный механизм амортизированного вывода.

Дифференцируемые релаксации Gumbel–Sinkhorn [2], методы жёсткого назначения [3, 4] и релаксации сортировки [5, 6] решают близкие комбинаторные задачи. Однако они не дают непосредственно вероятностной модели условной плотности, обучаемой по группам

непарных наблюдений. Требуется связать оценивание условного распределения с вычислимым вариационным выводом и ограничением, приближающим скрытую переменную к матрице перестановки.

1.3 Цель и основные результаты

Цель работы состоит в том, чтобы сделать вероятностное восстановление зависимости по группам непарных данных вычислимым при росте размера групп и обеспечить обработку новых групп без повторного решения отдельной задачи оптимизации. Для достижения этой цели в работе получены следующие результаты.

1. Сформулирована вариационная задача восстановления условного распределения при скрытом внутригрупповом сопоставлении и выведена соответствующая функция потерь на основе отрицательной нижней оценки обоснованности.
2. Предложено использовать Gumbel–Sinkhorn-преобразование для дифференцируемого ограничения латентной матрицы назначений множеством мягких перестановок.
3. Разработаны два подхода с разными параметризациями: амортизированный нейросетевой CatVAE, обучаемый стохастическим градиентным методом, и модель глобальной смеси сдвигов, обучаемая модифицированным EM с Sinkhorn-аппроксимацией E-шага и аналитическим M-шагом.
4. Проведено сравнение с энтропийным транспортным оператором Байера и др. [1] по L_2 -ошибке восстановления плотности при разных уровнях шума, размерах групп и объёмах данных.

2 Обзор и постановка задачи

2.1 Обозначения

Основные обозначения приведены в Таблице 1. На общем уровне p_θ обозначает условное распределение модели, а q_ϕ — вариационное распределение. Их конкретные параметризации вводятся в Разделе 3.

Таблица 1: Обозначения, используемые в работе.

Символ	Значение
p^*	истинное распределение данных
$p_\theta(y \mid x)$	условное распределение модели с параметрами θ
q_ϕ	вариационное распределение с параметрами ϕ
p_Z	априорное распределение скрытой переменной
N	число независимых групп
M	число точек в группе
x_m^n, y_m^n	m -е значения x и y в группе n
x^n, y^n	векторы $(x_1^n, \dots, x_M^n)$ и $(y_1^n, \dots, y_M^n)$
$\sigma^n \in S_M$	скрытая внутригрупповая перестановка группы n
S_M	симметрическая группа перестановок множества $\{1, \dots, M\}$
z	мягкая матрица назначений из $[0, 1]^{M \times M}$
$\mathcal{B}_M$	многогранник дважды стохастических матриц
$\mathbb{S}^1 = \mathbb{R}/\mathbb{Z}$	одномерный тор
$\tilde{\mathcal{N}}$	обёрнутое нормальное распределение на торе
$\text{KL}(\cdot \parallel \cdot)$	дивергенция Кульбака–Лейблера
K	число компонент смеси в конкретной параметризации
τ	температура Sinkhorn-преобразования
β	вес KL-регуляризатора
ϵ	стандартное отклонение порождающего шума

2.2 Формальная постановка задачи

Даны N независимых групп. Для группы $n \in \{1, \dots, N\}$ наблюдаются два набора по M элементов,

$$x^n = (x_1^n, \dots, x_M^n), \quad y^n = (y_1^n, \dots, y_M^n). \quad (1)$$

До потери соответствия элементы были получены как парные наблюдения из неизвестного совместного распределения. Затем значения y были переупорядочены скрытой перестановкой $\sigma^n \in S_M$. Следовательно, x_m^n образует истинную пару с $y_{\sigma^n(m)}^n$, но значение σ^n при обучении неизвестно.

Требуется оценить условное распределение $p^*(y \mid x)$ с помощью параметрической модели $p_\theta(y \mid x)$. При условной независимости пар внутри группы и скрытой перестановке

групповое правдоподобие имеет вид

$$\begin{aligned} p_\theta(y^n | x^n) &= \sum_{\sigma \in S_M} p(\sigma) p_\theta(y^n | x^n, \sigma) \\ &= \sum_{\sigma \in S_M} p(\sigma) \prod_{m=1}^M p_\theta(y_{\sigma(m)}^n | x_m^n). \end{aligned} \quad (2)$$

При отсутствии априорной информации о перестановках используется равномерное распределение

$$p(\sigma) = \frac{1}{M!}, \quad \sigma \in S_M. \quad (3)$$

Целью обучения служит максимизация суммы логарифмов группового правдоподобия по параметрам θ . Точное вычисление (2) требует учёта $M!$ перестановок и становится трудно-вычислимым при росте M .

2.3 Аппроксимация Байера и др.

Постановка восстановления распределения по группам непарных данных предложена Байером и др. [1]. Авторы начинают с точного правдоподобия, соответствующего усреднению произведения попарных плотностей по всем перестановкам, как в (2). Получаемая оценка максимального правдоподобия имеет факториальную вычислительную сложность по размеру группы.

Для получения вычислимого функционала Байер и др. заменяют зависимые координаты случайно переставленной группы их независимыми маргинальными распределениями. В обозначениях настоящей работы приближённое отрицательное логарифмическое правдоподобие записывается как

$$\tilde{\mathcal{J}}_N(\theta) = -\frac{1}{NM} \sum_{n=1}^N \sum_{j=1}^M \log \left[\frac{1}{M} \sum_{k=1}^M p_\theta(y_j^n | x_k^n) \right] \longrightarrow \min_{\theta}. \quad (4)$$

Вместо суммы по $M!$ перестановкам здесь для каждой группы вычисляются M^2 попарных плотностей. Цена аппроксимации состоит в отказе от совместного распределения назначений: выражение (4) не задаёт единую биекцию между элементами группы.

В работе Байера и др. пространство допустимых плотностей строится с помощью энтропийных транспортных ядер. Параметры плотности оцениваются минимизацией приближённого отрицательного логарифмического правдоподобия; после дискретизации для этого используется модифицированный EMM-L-алгоритм с ограничениями на переходные вероятности. Таким образом, транспортное ядро задаёт семейство моделей, а обучение остаётся оцениванием методом максимального правдоподобия.

2.4 Жёсткое назначение в нейросетевых моделях

Deep Perm-Set Net [3] и DETR [4] используют Hungarian matching для выбора дискретного соответствия между предсказанным и целевым наборами. После выбора соответствия

параметры модели обновляются по функции потерь для сопоставленных элементов; дифференцирование через сам алгоритм назначения этим методам не требуется.

Такое жёсткое назначение нельзя непосредственно использовать как репараметризуемый латентный слой вариационного автоэнкодера: Hungarian matching является дискретной недифференцируемой операцией и не передаёт градиент от вариационной целевой функции к параметрам распределения назначений. Непрерывная Sinkhorn-релаксация сохраняет мягкие веса возможных назначений и допускает сквозное дифференцирование. Благодаря этому нейросетевую версию модели можно обучать по мини-батчам стохастическим градиентным методом, а обученный энкодер амортизирует вывод для новых групп.

3 Метод

Неизвестное соответствие внутри каждой группы естественно представить скрытой перестановкой. Тогда восстановление зависимости сводится к совместному оцениванию условного распределения наблюдений и распределения скрытой перестановки. В работе эта идея реализуется двумя разными способами. В нейросетевом подходе оба распределения задаются нейронными сетями, образующими вариационный автоэнкодер, и обучаются стохастическим градиентным методом. В подходе с явными смесями условный закон и ответственности имеют заданную аналитическую форму, поэтому их параметры обновляются модифицированным ЕМ-алгоритмом без обратного распространения.

3.1 Нейросетевой вариационный подход

В первом подходе условное распределение $p_\theta(y \mid x)$ параметризуется нейросетевым декодером, а вариационное распределение перестановки $q_\phi(\sigma \mid x^n, y^n)$ — нейросетевым энкодером вместе с Gumbel–Sinkhorn-преобразованием. Параметры θ и ϕ оптимизируются совместно как параметры вариационного автоэнкодера.

3.1.1 Вариационная целевая функция

Для группы n используется точное маргинальное правдоподобие со скрытой перестановкой из формулы (2):

$$p_\theta(y^n \mid x^n) = \sum_{\sigma \in S_M} p(\sigma) \prod_{m=1}^M p_\theta(y_{\sigma(m)}^n \mid x_m^n), \quad p(\sigma) = \frac{1}{M!}. \quad (5)$$

Прямая максимизация требует суммирования по $M!$ перестановкам. Чтобы избежать этого перебора, вводится вариационное распределение $q_\phi(\sigma \mid x^n, y^n)$ на всём множестве S_M . После замены меры и применения неравенства Йенсена получаем

$$\begin{aligned} \log p_\theta(y^n \mid x^n) &= \log \mathbb{E}_{q_\phi} \left[\frac{p(\sigma) \prod_{m=1}^M p_\theta(y_{\sigma(m)}^n \mid x_m^n)}{q_\phi(\sigma \mid x^n, y^n)} \right] \\ &\geq \mathbb{E}_{q_\phi} \left[\sum_{m=1}^M \log p_\theta(y_{\sigma(m)}^n \mid x_m^n) \right] - \text{KL}(q_\phi(\sigma \mid x^n, y^n) \parallel \mathcal{U}(S_M)) =: \mathcal{E}^n(\theta, \phi). \end{aligned} \quad (6)$$

Отрицательная нижняя оценка обоснованности для всей выборки равна

$$\boxed{\mathcal{L}_{\text{NELBO}}(\theta, \phi) = -\frac{1}{N} \sum_{n=1}^N \mathcal{E}^n(\theta, \phi).} \quad (7)$$

Разрыв между логарифмом правдоподобия и ELBO имеет точный вид

$$\log p_\theta(y^n \mid x^n) = \mathcal{E}^n(\theta, \phi) + \text{KL}(q_\phi(\sigma \mid x^n, y^n) \parallel p_\theta(\sigma \mid x^n, y^n)). \quad (8)$$

Таким образом, в теоретической постановке скрытая переменная остаётся одной перестановкой всей группы: перехода к независимым локальным назначениям нет. При совпадении вариационного и истинного апостериорного распределений граница становится точной.

3.1.2 Gumbel–Sinkhorn-параметризация перестановки

Энкодер должен задавать распределение на перестановках, однако произвольная модель выдаёт неограниченную матрицу оценок. Перестановочная матрица $P \in \{0,1\}^{M \times M}$ содержит одну единицу в каждой строке и каждом столбце. Её непрерывной релаксацией служит многогранник Биркгофа

$$\mathcal{B}_M = \left\{ P \in \mathbb{R}_{\geq 0}^{M \times M} : \sum_{k=1}^M P_{mk} = 1 \ \forall m, \quad \sum_{m=1}^M P_{mk} = 1 \ \forall k \right\}. \quad (9)$$

По теореме Биркгофа–фон Неймана $\mathcal{B}_M$ является выпуклой оболочкой матриц перестановок, поэтому его элементы интерпретируются как мягкие биективные сопоставления.

Пусть $\Phi = (\ell_{mk}) \in \mathbb{R}^{M \times M}$ — матрица логитов энкодера. Для дифференцируемой выборки к её элементам добавляется независимый шум $G_{mk} \sim \text{Gumbel}(0,1)$, после чего применяется Sinkhorn-нормализация [2]. В логарифмическом пространстве одна итерация имеет вид

$$\log \alpha_{mk} \leftarrow \log \alpha_{mk} - \text{logsumexp}_{k'}(\log \alpha_{mk'}), \quad (10)$$

$$\log \alpha_{mk} \leftarrow \log \alpha_{mk} - \text{logsumexp}_{m'}(\log \alpha_{m'k}). \quad (11)$$

Повторение нормализаций строк и столбцов приближает экспоненту результата к $\mathcal{B}_M$. В режиме обучения и при детерминированном выводе используются соответственно

$$z = \text{Sinkhorn}\left(\frac{\Phi + G}{\tau}\right), \quad z^{\text{det}} = \text{Sinkhorn}\left(\frac{\Phi}{\tau}\right). \quad (12)$$

При конечной температуре $\tau > 0$ матрицы являются мягкими перестановками из $\mathcal{B}_M$, а при $\tau \rightarrow 0$ концентрируются около вершин, соответствующих жёстким перестановкам. Слишком малая температура ухудшает численную устойчивость матричного масштабирования [7]. Одна Sinkhorn-итерация требует $O(M^2)$ операций, а T итераций — $O(TM^2)$.




Рис. 1: Преобразование читается слева направо: к попарным логитам энкодера добавляется шум Gumbel, после чего Sinkhorn-нормализация строк и столбцов формирует мягкую матрицу перестановки. При детерминированном выводе шум не добавляется.

3.1.3 Нейросетевой энкодер

Для каждой пары (x_m^n, y_k^n) строится периодическое представление

$$[\sin(2\pi x_m^n), \cos(2\pi x_m^n), \sin(2\pi y_k^n), \cos(2\pi y_k^n)] \in \mathbb{R}^4. \quad (13)$$

Общая для всех пар полносвязная сеть преобразует это представление в логит ℓ_{mk}^n . Все логиты образуют матрицу Φ^n , которая затем обрабатывается Gumbel–Sinkhorn-преобразованием (12). Параметры ϕ общие для всех групп, поэтому энкодер амортизирует вывод: для новой группы не требуется отдельная оптимизация вариационных параметров.




Рис. 2: Нейросетевая параметризация попарных логитов вариационного распределения.

3.1.4 Нейросетевой декодер

Условное распределение задаётся нейросетевой смесью из K компонент:

$$p_\theta(y | x) = \sum_{r=1}^K \pi_r(x) \tilde{\mathcal{N}}(y | \mu_r(x), \epsilon^2). \quad (14)$$

Сеть получает периодические признаки $[\sin(2\pi x), \cos(2\pi x)]$ и возвращает средние $\mu_r(x)$ и логиты весов $\alpha_r(x)$, причём

$$\pi_r(x) = \frac{\exp(\alpha_r(x))}{\sum_{s=1}^K \exp(\alpha_s(x))}. \quad (15)$$

Дисперсия ϵ^2 фиксируется и совпадает с уровнем шума генератора в синтетическом эксперименте.




Рис. 3: Нейросетевая параметризация средних и весов условной смеси.

Данные рассматриваются на одномерном торе $\mathbb{S}^1 = \mathbb{R}/\mathbb{Z}$; для $y, \mu \in \mathbb{S}^1$ круговой остаток определяется как $r(y, \mu) = ((y - \mu + \frac{1}{2}) \bmod 1) - \frac{1}{2}$. Логарифм обёрнутой нормальной плотности приближается вкладом ближайшего периодического образа:

$$\log \tilde{\mathcal{N}}(y | \mu, \epsilon^2) \approx -\frac{1}{2} \left[\log(2\pi\epsilon^2) + \frac{r(y, \mu)^2}{\epsilon^2} \right]. \quad (16)$$

При малом ϵ вклады дальних периодических образов экспоненциально малы.

Для каждой пары точек определяется модельная плотность

$$p_\theta(y_j^n | x_m^n) = \sum_{r=1}^K \pi_r(x_m^n) \tilde{\mathcal{N}}(y_j^n | \mu_r(x_m^n), \epsilon^2) \quad (17)$$

и попарное отрицательное логарифмическое правдоподобие

$$D_{mj}^n = -\log p_\theta(y_j^n | x_m^n). \quad (18)$$

Мягкая перестановка z^n задаёт реконструкционный член

$$\mathcal{L}_{\text{rec}}^n = \sum_{m=1}^M \sum_{j=1}^M z_{mj}^n D_{mj}^n. \quad (19)$$

3.1.5 Обучение стохастическим градиентным методом

Формулы (6)–(7) задают точную вариационную цель на пространстве перестановок. В реализации распределение Gumbel–Sinkhorn имеет неявную плотность, поэтому точный KL на S_M недоступен. Для одной группы оптимизируется дифференцируемый суррогат

$$\mathcal{L}^n(\theta, \phi) = \underbrace{\sum_{m,k} z_{mk}^n D_{mk}^n}_{\text{реконструкция}} + \beta \underbrace{\frac{1}{M} \sum_{m,k} z_{mk}^{n,\text{det}} (\log z_{mk}^{n,\text{det}} + \log M)}_{\text{построчный KL-суррогат}}. \quad (20)$$

Реконструкционный член оценивается одной Gumbel–Sinkhorn-выборкой, а KL-регуляризатор вычисляется по строкам детерминированной мягкой перестановки. Это практическая непрерывная аппроксимация оптимизации точной перестановочной NELBO, но не замена самой теоретической скрытой переменной набором независимых назначений.

Обе матрицы из (12) дифференцируемы по Φ . В основной реализации прямой проход выполняется фиксированным числом Sinkhorn-итераций, а обратный проход — неявным дифференцированием неподвижной точки [8]. Разворачивание итераций средствами автоматического дифференцирования сохранено как альтернативный вариант. Градиенты средней потери мини-батча ограничиваются по норме и используются оптимизатором Adam. Вес β линейно увеличивается от 0 до 1, тогда как температура τ фиксирована на протяжении всего запуска.

После обучения новая группа обрабатывается одним прямым проходом энкодера и детерминированной Sinkhorn-проекцией. Для извлечения жёсткой перестановки может применяться Hungarian matching; используемый в диагностических экспериментах построчный $\arg \max$ не гарантирует биективность.

Algorithm 1 Нейросетевой вариационный подход с Gumbel–Sinkhorn-релаксацией

Require: группы $\{(x^n, y^n)\}_{n=1}^N$; расписание $\beta(t)$; фиксированная температура τ ; фиксированная дисперсия ϵ^2

- 1: инициализировать параметры энкодера ϕ и декодера θ
- 2: **for** каждый шаг обучения t **do**
- 3: выбрать мини-батч $\mathcal{B}$ групп
- 4: **for** каждая группа $n \in \mathcal{B}$ **do**
- 5: $\Phi^n \leftarrow \text{Encoder}_\phi(x^n, y^n)$
- 6: $z^n \leftarrow \text{Sinkhorn}((\Phi^n + G)/\tau)$
- 7: $z^{n, \text{det}} \leftarrow \text{Sinkhorn}(\Phi^n/\tau)$
- 8: вычислить $D_{mk}^n = -\log p_\theta(y_k^n | x_m^n)$
- 9: вычислить $\mathcal{L}^n$ по (20)
- 10: **end for**
- 11: обновить (θ, ϕ) градиентным шагом по средней потере мини-батча
- 12: **end for**
- 13: **вывод:** применить детерминированную Sinkhorn-проекцию и извлечь перестановку

3.2 Подход с явными смесями

Во втором подходе нейросетевые энкодер и декодер не используются. Условное распределение задаётся глобальной смесью сдвигов, а распределение скрытых переменных — явными ответственностями назначения и компоненты. Благодаря этой параметризации параметры можно обновлять аналитически в модифицированном ЕМ-алгоритме, не применяя SGD и обратное распространение.

3.2.1 Явная параметризация распределений

Для каждой исходной точки вводится номер компоненты $c_m \sim \text{Cat}(\pi_1, \dots, \pi_K)$, после чего

$$y_{\sigma(m)} \sim \tilde{\mathcal{N}}(x_m + s_{c_m}, \epsilon^2). \quad (21)$$

Сдвиги $s_1, \dots, s_K$ и веса $\pi_1, \dots, \pi_K$ общие для всех точек и групп; $\theta = (s, \pi)$. В отличие от нейросетевого декодера, средние имеют заданный вид $x + s_c$, поэтому число оцениваемых параметров не зависит от сложности нейронной сети.

Для одной группы попарное логарифмическое правдоподобие и условная ответственность компоненты равны

$$L_{mk} = \log \sum_{c=1}^K \pi_c \tilde{\mathcal{N}}(y_k | x_m + s_c, \epsilon^2), \quad (22)$$

$$w_{mkc} = \frac{\pi_c \tilde{\mathcal{N}}(y_k | x_m + s_c, \epsilon^2)}{\sum_{c'} \pi_{c'} \tilde{\mathcal{N}}(y_k | x_m + s_{c'}, \epsilon^2)}. \quad (23)$$

Здесь w_{mkc} вычисляется аналитически из текущих параметров и играет роль явного факторизованного распределения компоненты при фиксированной паре (m, k) .

3.2.2 Модифицированный Е-шаг

Точное апостериорное распределение назначения требует суммы по всем перестановкам:

$$q_{mk}^{\text{exact}} = \sum_{\sigma \in S_M: \sigma(m)=k} \frac{\prod_i \exp L_{i,\sigma(i)}}{\sum_{\sigma' \in S_M} \prod_i \exp L_{i,\sigma'(i)}}. \quad (24)$$

В модифицированном ЕМ эта часть Е-шага заменяется энтропийно-регуляризованным Sinkhorn-планом

$$q = \text{Sinkhorn}(L/\tau) \in \mathcal{B}_M, \quad q = \arg \max_{Q \in \mathcal{B}_M} \{ \langle Q, L \rangle + \tau H(Q) \}. \quad (25)$$

Совместная ответственность назначения и компоненты факторизуется как

$$r_{mkc} = q_{mk} w_{mkc}. \quad (26)$$

Таким образом, компонентная часть Е-шага имеет аналитический вид, а распределение перестановки вычисляется посредством Sinkhorn-аппроксимации вместо факториального перебора.

3.2.3 Аналитический М-шаг

После суммирования ответственностей по всем группам веса смеси обновляются формулой

$$S_c = \sum_{n,m,k} r_{mkc}^{(n)}, \quad \pi_c \leftarrow \frac{S_c}{\sum_{c'} S_{c'}}. \quad (27)$$

Сдвиг обновляется круговым средним разностей $\delta_{mk} = y_k - x_m$:

$$s_c \leftarrow \frac{1}{2\pi} \text{atan2} \left(\sum_{n,m,k} r_{mkc}^{(n)} \sin(2\pi \delta_{mk}), \sum_{n,m,k} r_{mkc}^{(n)} \cos(2\pi \delta_{mk}) \right) \bmod 1. \quad (28)$$

Оба обновления вычисляются непосредственно и не требуют градиентных шагов. При нулевой ответственности компоненты её предыдущий сдвиг сохраняется.

Алгоритм является модифицированным ЕМ: точное апостериорное распределение перестановки заменено Sinkhorn-планом, а для обёрнутой нормальной плотности круговое моментное обновление не обязано совпадать с точным максимумом правдоподобия. Поэтому стандартная гарантия монотонного роста правдоподобия классического ЕМ здесь не применяется. Температура τ фиксирована на протяжении каждого запуска; в основных экспериментах используется $\tau = 1$, а влияние других фиксированных значений исследуется отдельно. Сдвиги инициализируются по модам гистограммы попарных круговых разностей, а при невозможности выделить моды — почти равномерно.

Algorithm 2 Модифицированный ЕМ для глобальной смеси сдвигов

Require: группы $\{(x^n, y^n)\}_{n=1}^N$; число компонент K ; фиксированная температура τ ; фиксированная дисперсия ϵ^2

- 1: инициализировать сдвиги s_c и положить $\pi_c = 1/K$
 - 2: **for** итерация $t = 0, 1, \dots$ **do**
 - 3: вычислить L_{mk} и аналитические ответственности w_{mkc}
 - 4: выполнить модифицированный Е-шаг: $q = \text{Sinkhorn}(L/\tau)$ и $r_{mkc} = q_{mk}w_{mkc}$
 - 5: выполнить аналитический М-шаг: обновить π_c по (27) и s_c по (28)
 - 6: **end for**
 - 7: **вывод:** вычислить q при той же температуре и извлечь перестановку
-

4 Эксперименты

Эксперименты предназначены для проверки двух аспектов предложенного подхода: качества восстановления скрытого сопоставления и качества оценки условной плотности. Исследуется зависимость результатов от уровня шума ϵ , размера группы M и числа групп N . В качестве внешней точки сравнения используется энтропийный транспортный оператор Байера и др. [1], решающий ту же статистическую задачу.

4.1 Синтетические данные

Используется общий с референсной работой синтетический пример на одномерном торе $\mathbb{S}^1 = [0,1)$. Величина x имеет равномерное распределение, а условный закон $Y \mid X = x$ представляет собой бимодальную обёрнутую гауссову смесь:

$$p^*(x) = \mathcal{U}[0,1), \quad p^*(y \mid x) = \frac{1}{2}\tilde{\mathcal{N}}(x, \epsilon^2) + \frac{1}{2}\tilde{\mathcal{N}}(x + 0.3, \epsilon^2). \quad (29)$$

Здесь ϵ обозначает стандартное отклонение шума. Для каждой группы независимо генерируются M пар, после чего значения y переупорядочиваются случайной перестановкой. Алгоритм получает только два набора значений и не использует истинное соответствие при обучении. Набор данных содержит N таких групп.




Рис. 4: Синтетические данные на торе при $\epsilon = 0.05$. Слева показаны 10^3 пар (x, y) , справа — их двумерная гистограмма. Полосы соответствуют компонентам $y \approx x$ и $y \approx x + 0.3$ с периодическим продолжением.

4.2 Метрики и протокол

Ошибка восстановления плотности. Поскольку плотность равномерного распределения X на $[0,1)$ равна единице, на рассматриваемой области выполняется $p(x, y) = p(y \mid x)$.

Истинная и восстановленная плотности сравниваются на равномерной сетке размера $E \times E$:

$$L_2 = \frac{1}{E} \|p^*(x,y) - \hat{p}_\theta(x,y)\|_2 = \left(\frac{1}{E^2} \sum_{i=1}^E \sum_{j=1}^E (p^*(x_i, y_j) - \hat{p}_\theta(x_i, y_j))^2 \right)^{1/2}. \quad (30)$$

Меньшее значение соответствует более точному восстановлению. Для нейросетевой модели плотность определяется условной смесью (14); для глобальной смеси сдвигов используется $\hat{p}_\theta(y | x) = \sum_c \pi_c \tilde{\mathcal{N}}(y | x + s_c, \epsilon^2)$.

Точность локальных назначений. Для диагностического эксперимента истинная перестановка сохраняется только на этапе оценки. Предсказанный индекс определяется построчным $\arg \max$ мягкой матрицы назначений, после чего вычисляется доля совпавших индексов. Эта метрика оценивает локальные назначения и, в отличие от Hungarian matching, сама по себе не гарантирует биективность всей предсказанной перестановки.

Протокол. Каждая точка кривых соответствует медиане по пяти независимым запускам. Полупрозрачная область показывает межквартильный размах. Основные гиперпараметры приведены в Таблице 2. Нейросетевая модель обучается стохастическим градиентным методом, а глобальная смесь сдвигов — полнобatchesвым модифицированным ЕМ с Sinkhorn-аппроксимацией Е-шага и аналитическим М-шагом. Это два подхода с разными параметризациями: модель сдвигов использует заранее известную структуру синтетического генератора, тогда как CatVAE задаёт более общий условный закон нейронными сетями.

Таблица 2: Основные параметры экспериментов.

Параметр	CatVAE	Глобальная смесь сдвигов
Уровни шума ϵ	{0.01, 0.025, 0.05}	
Число компонент K	2	
Сетка метрики E	100	
Число запусков	5 (медиана и IQR)	
Число итераций	5000 (M, N); 2500 (ϵ)	200
Температура τ	1 (фиксирована)	
Число Sinkhorn-итераций	50	50
Шаг обучения	10^{-3}	—
Число групп в опыте по M	20	20
Исследованный диапазон M	1 ... 512	
Диапазон N при $M = 20$	1 ... 407	

Референсные значения взяты из результатов Байера и др. для того же синтетического распределения и той же L_2 -метрики. Поэтому сравнение характеризует качество оценок на общей задаче, но не является изолированным сравнением оптимизаторов или времени работы.

4.3 Восстановление скрытого сопоставления

На Рисунке 5 показаны результаты CatVAE при $M = 2$. На левых панелях значения соединены по наблюдаемому после перемешивания индексу. На правых панелях пары образованы по построчному $\arg \max$ мягкой матрицы назначений. Зелёный цвет соответствует совпадению с сохранённым истинным индексом, красный — ошибке.




Рис. 5: Локальные назначения CatVAE при $M = 2$ для $\epsilon = 0.01$ (сверху), $\epsilon = 0.025$ (в центре) и $\epsilon = 0.05$ (снизу). Слева показано исходное переупорядочивание, справа — назначения по построчному $\arg \max$.

Численные значения приведены в Таблице 3. При случайном выборе одного из двух индексов ожидаемая точность составляет 50%. Полученные значения существенно выше этого уровня. С ростом ϵ компоненты условной смеси сильнее перекрываются, а наблюдаемая точность назначений снижается. Этот эксперимент подтверждает, что матрица назначений содержит информацию об исходных парах, но не доказывает однозначную восстановимость каждой перестановки при произвольных M и ϵ .

Таблица 3: Точность локальных назначений CatVAE при $M = 2$.

Уровень шума ϵ	Точность
0.01	98.0%
0.025	95.6%
0.05	89.7%

4.4 Влияние размера группы M

На Рисунке 6 показана зависимость L_2 -ошибки от числа точек в группе при фиксированных $N = 20$. Сплошные линии соответствуют двум исследуемым параметризациям, штриховые — референсному методу. Цвет обозначает уровень порождающего шума.




Рис. 6: L_2 -ошибка в зависимости от M при $N = 20$. Сплошные кривые показывают медиану по пяти запускам, области — IQR, штриховые кривые — референс. Синий, оранжевый и зелёный цвета соответствуют $\epsilon = 0.01, 0.025$ и 0.05 .

При малых и умеренных M глобальная смесь сдвигов даёт меньшую ошибку, чем референсный метод. Этот результат ожидаем для параметризации, совпадающей по форме с генератором данных: требуется оценить только два общих сдвига и их веса. Он не позволяет приписать преимущество самому модифицированному ЕМ независимо от выбранной модели.

При $\tau = 1$ ошибка смеси сдвигов не возрастает с увеличением M : во всём исследованном диапазоне она остаётся существенно ниже референсных значений. Следовательно, сам по себе рост матрицы назначений в данном эксперименте не приводит к наблюдавшемуся ранее излому. Зависимость этого эффекта от температуры отдельно исследуется ниже.

Ошибка CatVAE остаётся сопоставимой с референсом, но в большинстве режимов превышает ошибку специализированной смеси сдвигов. Возможной причиной является большая гибкость условной модели и, следовательно, более сложная совместная оценка плотности и назначений.

4.5 Влияние числа групп N

На Рисунке 7 показана зависимость ошибки от числа групп при $M = 20$. Сплошные кривые соответствуют трём уровням шума исследуемых моделей. Штриховые кривые показывают референс при $\epsilon = 0.05$ и трёх значениях силы энтропийной регуляризации ϵ .




Рис. 7: L_2 -ошибка в зависимости от N при $M = 20$. Сплошные кривые соответствуют $\epsilon \in \{0.01, 0.025, 0.05\}$; штриховые кривые — референсу при $\epsilon = 0.05$ и $\epsilon \in \{0.001, 0.0025, 0.01\}$. Показаны медиана и IQR по пяти запускам.

При $\tau = 1$ ошибка глобальной смеси сдвигов уменьшается с ростом N и становится близкой к нулю при всех трёх уровнях шума. Это соответствует низкой размерности правильно специфицированной модели: дополнительные группы уточняют оценки общих сдвигов и весов. В частности, плато при $\epsilon = 0.05$, возникающее при меньших температурах, не является неизбежным следствием перекрытия компонент.

При малых N отдельные кривые немонотонны, а межквартильный размах увеличивается. Это указывает на высокую чувствительность оценки к конкретной выборке и инициализации при дефиците данных. Гарантии монотонности классического ЕМ здесь неприменимы по двум причинам: Е-шаг модифицирован Sinkhorn-аппроксимацией, и сравниваются разные обучающие выборки, а не соседние итерации одного запуска. Поэтому немонотонность по N рассматривается как эмпирическая нестабильность малой выборки, а не как следствие свойства ELBO.

В совокупности эксперименты показывают, что обе параметризации способны восстанавливать условную плотность из непарных групп. Специализированная смесь сдвигов наиболее точна при совпадении её структуры с генератором, тогда как CatVAE не использует предположение о глобально постоянных сдвигах. Для модифицированного ЕМ при низкой температуре качество ограничивается устойчивостью Sinkhorn-аппроксимации Е-шага, как показывает следующий опыт.

Влияние температуры. Для модифицированного ЕМ дополнительно проведены эксперименты при $\tau \in \{0.05, 0.1, 0.2, 0.5\}$. Все остальные параметры совпадают с основным протоколом. Результаты для каждого значения τ образуют отдельный столбец на Рисунке 8: верхний ряд соответствует варьированию M при $N = 20$, нижний — варьированию N при $M = 20$.




Рис. 8: Чувствительность глобальной смеси сдвигов к температуре τ . Верхний ряд: L_2 -ошибка в зависимости от M при $N = 20$; нижний ряд: ошибка в зависимости от N при $M = 20$. Один столбец соответствует одному значению τ . Обозначения кривых совпадают с Рисунками 6 и 7.

В эксперименте по M при всех исследованных $\tau < 1$ ошибка после некоторого порогового размера группы возрастает к одним и тем же уровням; при малых τ хорошо различимо плато. Это согласуется с формой Е-шага (25): деление L на малую температуру усиливает различия попарных логарифмических правдоподобий, поэтому план q становится почти дискретным. Случайное небольшое преимущество одной компоненты тогда даёт ей почти всю ответственность $r_{mkc} = q_{mk}w_{mkc}$. Обновления (27) и (28) усиливают это преимущество, и вторая компонента теряет вес либо совмещается с первой. В результате оценка условной плотности фактически содержит только одну из двух истинных мод. При меньшей τ эта положительная обратная связь включается резче, что объясняет более резкий излом кривых. Совпадение наблюдаемых уровней плато с однокомпонентным пределом служит дополнительным свидетельством такого коллапса.

Этот предел можно вычислить явно. Обозначим плотность обёрнутого нормального распределения с нулевым средним через $g_\epsilon(t) = \sum_{k \in \mathbb{Z}} \mathcal{N}(t + k \mid 0, \epsilon^2)$ и положим $d = 0.3$. Истинная плотность разности $y - x$ равна $\frac{1}{2}g_\epsilon(t) + \frac{1}{2}g_\epsilon(t - d)$. Если оценка сохраняет только одну моду, например $\hat{p}(t) = g_\epsilon(t)$, то

$$L_{2,\text{coll}}^2 = \frac{1}{4} \int_0^1 (g_\epsilon(t - d) - g_\epsilon(t))^2 dt \quad (31)$$

$$= \frac{1}{2} \sum_{\ell \in \mathbb{Z}} e^{-4\pi^2 \epsilon^2 \ell^2} (1 - \cos(2\pi \ell d)). \quad (32)$$

Поскольку d велик по сравнению с исследуемыми ϵ , перекрытие мод мало и

$$L_{2,\text{coll}} \simeq \frac{1}{2\pi^{1/4}\sqrt{\epsilon}}. \quad (33)$$

Отсюда для дисперсий $\epsilon^2 \in \{10^{-4}, 6.25 \cdot 10^{-4}, 2.5 \cdot 10^{-3}\}$ получаются значения $L_{2,\text{coll}} \approx 3.76, 2.38$ и 1.68 соответственно. Именно около этих уровней располагаются синяя, оранжевая и зелёная кривые после перехода.

5 Обсуждение

5.1 Сравнение предложенных подходов

В работе рассмотрена задача восстановления зависимости между X и Y по группам, внутри которых исходное попарное соответствие утрачено. Для её решения разработаны два подхода, различающиеся параметризацией скрытого распределения, моделью условной плотности и способом обучения.

В нейросетевом подходе CatVAE условное распределение задаётся декодером, а вариационное распределение перестановки — энкодером с Gumbel–Sinkhorn-преобразованием. Теоретическая NELBO выводится непосредственно из точного группового правдоподобия с одной перестановкой $\sigma \in S_M$ и не использует факторизацию по локальным назначениям (Раздел 3.1.1). В реализации непрерывная Gumbel–Sinkhorn-релаксация и построчный KL образуют дифференцируемый суррогат, позволяющий совместно обучать энкодер и декодер методом SGD. После обучения новая группа обрабатывается прямым проходом энкодера и детерминированной Sinkhorn-проекцией без повторной оптимизации параметров.

Во втором подходе условный закон ограничивается глобальной смесью сдвигов, а ответственности назначения и компоненты вычисляются явно. Обучение выполняется модифицированным ЕМ (Раздел 3.2): компонентная часть Е-шага имеет аналитический вид, распределение перестановки приближается Sinkhorn-планом, а веса и периодические сдвиги обновляются явными формулами на М-шаге. Нейронные сети, SGD и обратное распространение в этом подходе не используются.

Различие результатов двух подходов нельзя сводить только к различию оптимизаторов. CatVAE использует более гибкий класс условных распределений и амортизирует вывод, но требует обучения нейронных сетей. Модифицированный ЕМ использует сильное предположение о глобальной смеси сдвигов и благодаря этому получает интерпретируемые аналитические обновления. Его преимущество на синтетическом бенчмарке отражает в том числе совпадение параметризации с порождающей моделью.

5.2 Интерпретация экспериментальных результатов

Эксперименты показывают, что предложенные подходы восстанавливают не только плотность, но и скрытую структуру сопоставления. При $M = 2$ CatVAE достигает точности 98.0% при $\epsilon = 0.01$ по сравнению со случайным уровнем 50%; с ростом шума точность снижается до 89.7% при $\epsilon = 0.05$ (Рис. 5 и Таблица 3). Восстановленные пары располагаются вдоль двух мод порождающего распределения, что подтверждает способность модели распутывать перестановку, а не только аппроксимировать маргинальные распределения наблюдаемых множеств.

По L_2 -ошибке плотности CatVAE на рассмотренном бенчмарке остаётся одного порядка с энтропийным транспортным оператором, но не демонстрирует устойчивого превосходства над ним (Рис. 6). Нейросетевой подход платит за более общий класс декодеров и амортизацию вывода. Модифицированный ЕМ при малом и умеренном шуме и малых или средних M заметно превосходит референс. Этот результат получен в благоприятном режиме,

где предположение о глобальной смеси сдвигов совпадает с генератором данных, и не должен переноситься на произвольные условные распределения без дополнительной проверки.

Рост числа групп N в среднем уменьшает ошибку обоих подходов. Для модифицированного ЕМ при $\epsilon \in \{0.01, 0.025\}$ нескольких десятков групп оказывается достаточно, чтобы оценить сдвиги и веса смеси с малой ошибкой (Рис. 7). Следовательно, групповые непарные наблюдения действительно содержат информацию о совместной зависимости: при подходящей модели накопление независимых групп позволяет восстановить параметры, хотя ни в одной группе правильные пары не предъявляются алгоритму.

5.3 Границы применимости

Основное вычислительное ограничение связано с размером группы M . Оба подхода избегают явного перебора $M!$ перестановок, но используют матрицу попарных оценок из M^2 элементов. В CatVAE она обрабатывается Gumbel–Sinkhorn-релаксацией, а в модифицированном ЕМ — Sinkhorn-аппроксимацией Е-шага. Стоимость одной итерации Sinkhorn имеет порядок $O(M^2)$, а качество мягкой перестановки зависит от температуры и числа нормализаций. Поэтому практическое применение ограничено группами, для которых матрица оценок помещается в память и Sinkhorn-проекция остаётся устойчивой.

Второе фундаментальное ограничение — идентифицируемость сопоставления. При $\epsilon = 0.05$ компоненты условной смеси сильнее перекрываются, точность восстановления пар падает, а ошибка ЕМ выходит на плато около 1.1, которое не устраняется увеличением N . В таком режиме несколько перестановок почти одинаково согласуются с наблюдениями, поэтому невозможность уверенно восстановить конкретное соответствие является свойством данных, а не только недостатком алгоритма.

Теоретическая вариационная постановка CatVAE использует точную скрытую перестановку, однако практическая функция обучения содержит Gumbel–Sinkhorn-релаксацию, одну выборку для реконструкционного члена и построчный KL-суррогат. В модифицированном ЕМ точный перестановочный Е-шаг заменён энтропийным транспортным планом, а круговое моментное обновление сдвига не обязано максимизировать точное правдоподобие обёрнутой нормальной смеси. Поэтому для него не действует стандартная гарантия монотонного роста правдоподобия классического ЕМ. Результаты также зависят от инициализации, температуры и числа итераций Sinkhorn.

Экспериментальная проверка ограничена синтетическими одномерными данными на торе с известными K и ϵ . Она не устанавливает качество подходов на многомерных или реальных данных.

5.4 Открытые задачи

Для больших групп требуется уменьшить квадратичные затраты на матрицу назначений, например за счёт разреженных кандидатных соответствий или иерархического сопоставления, не разрушая условие биективности. Другой открытый вопрос — построение более точной и при этом вычислимой аппроксимации апостериорного распределения по переста-

новкам как для Gumbel–Sinkhorn-обучения, так и для EM E-шага.

Для модели плотности естественным продолжением является совместное оценивание дисперсии, числа компонент и формы компонент вместо фиксации K и ϵ . Важна также проверка способности амортизированного энкодера переноситься между разными размерами групп и уровнями шума. Наконец, переход к многомерным пространствам, другим геометриям и реальным данным позволит установить, сохраняются ли наблюдаемые преимущества при отклонении от модели глобальных сдвигов. Отдельная теоретическая задача состоит в формулировке условий идентифицируемости совместного распределения по непарным группам.

5.5 Основные результаты

Основные результаты, полученные в работе, состоят в следующем.

1. Выведена вариационная нижняя граница непосредственно для точной скрытой перестановки группы, без факторизации по локальным назначениям.
2. Разработан нейросетевой CatVAE: энкодер с Gumbel–Sinkhorn-релаксацией и декодер условной обёрнутой гауссовой смеси совместно обучаются стохастическим градиентным методом и обеспечивают амортизированный вывод для новых групп.
3. Разработан отдельный подход с явной параметризацией глобальной смеси сдвигов, обучаемый модифицированным EM с Sinkhorn-аппроксимацией E-шага и аналитическими обновлениями весов и периодических сдвигов.
4. Экспериментально исследовано влияние шума, размера групп, объёма данных и Sinkhorn-температуры на качество обоих подходов.

Список литературы

- [1] Transfer operators from batches of unpaired points via entropic transport kernels / F. Beier, J. Piening, R. Beinert, G. Steidl // *arXiv preprint arXiv:2402.08425*. — 2024.
- [2] Learning latent permutations with Gumbel-Sinkhorn networks / G. Mena, D. Belanger, S. Linderman, J. Snoek // *arXiv preprint arXiv:1802.08665*. — 2018.
- [3] Deep Perm-Set Net: Learn to predict sets with unknown permutation and cardinality using deep neural networks / H. Rezatofighi, F. T. Motlagh, Q. Shi et al. // *arXiv preprint arXiv:1805.00613*. — 2018.
- [4] End-to-end object detection with transformers / N. Carion, F. Massa, G. Synnaeve et al. // European Conference on Computer Vision (ECCV). — Springer, 2020. — Pp. 213–229.
- [5] Prillo, S. SoftSort: A continuous relaxation for the argsort operator / S. Prillo, J. M. Eisenschlos // International Conference on Machine Learning (ICML). — PMLR, 2020. — Pp. 7793–7802.
- [6] Stochastic optimization of sorting networks via continuous relaxations / A. Grover, E. Wang, A. Zweig, S. Ermon // International Conference on Learning Representations (ICLR). — 2019.
- [7] Schmitzer, B. Stabilized sparse scaling algorithms for entropy regularized transport problems / B. Schmitzer // *SIAM Journal on Scientific Computing*. — 2019. — Vol. 41, no. 3. — Pp. A1443–A1481.
- [8] A unified framework for implicit Sinkhorn differentiation / M. Eisenberger, A. Toker, L. Leal-Taixé et al. // IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2022. — Pp. 509–518.